Edge Atlas / 端侧知识库技术说明

seekdb × 阶跃星辰 | EmbeddingGemma 2 | 本地实测 2026-10-29

提交位置与流程。 基于 2026-competition-ecosystem 的 d647275c，资产均在 stepfun/。Chrome/Edge 打开本地 Web 应用，文本导入 / 浏览器 Worker 向量化 / Node 接收已算向量 / seekdb 保存与混合检索 / 展示数据库排序及原文。无云端推理 API，无服务端 embedding 或结果回放。npm ci && npm run db:up && npm run models:download && npm run dev，入口 http://127.0.0.1:4177；Windows 使用 npm.cmd，Docker 在 WSL 中时脚本自动转交。

模型与量化。 原模型 google/embeddinggemma-2，Apache-2.0；采用 ONNX Community 导出，固定 revision daa72c51243991dfcaf9f9137d2c573d8f7790c0，Transformers.js 4.3.2 / ORT Web 1.31.0-dev.20260914-8d85527a0。移除视觉/音频配置，仅加载 270M 文本编码器；使用指定 query/document 前缀、图内 mean pooling 和投影、768 维 L2 归一化输出。使用发布的 INT8 model_quantized 图，不重新训练；FP32 同版本作基线。按图+外部权重+相同配置/分词器口径：FP32 1,116,768,801 B，WebGPU INT8 346,397,233 B，WASM INT8 346,398,301 B，压缩比约 3.22×。文件逐一记录 SHA-256；下载脚本验证来源字节数和 LFS 哈希。

后端与降级。 显式 device:'webgpu', dtype:'q8'，adapter 申请、会话创建、预热和后续推理失败时自动转 WASM/INT8，UI 显示实际后端、精度及原因。原图的 GatherBlockQuantized 不受 WASM 支持，故生成等价标准 ONNX Gather/Cast/Sub/Mul/Reshape 子图，保留全部 INT8 权重并共享原权重文件，仅反量化选中 token 行；20 组/81,920 元素数值对照最大误差 0，其余节点/权重不变。真实自动降级及 WASM 导入检索通过。Gemma 2 不使用存在数值范围争议的 FP16；备选 BGE 的真实 FP16 不可用 / WASM/INT8 路径也通过。

seekdb 与状态。 seekdb-js 1.4.0 / seekdb 1.4.0.0；每库独立集合，IK smart 全文索引、HNSW cosine 向量索引，显式禁用 SDK embedding function。registry 存模型指纹、写入/索引版本；稳定内容 ID 保证重复导入幂等，修改文件采用追加语义。批内 upsert 与版本更新在事务中提交，整次导入后统一 dbms_index_manager.refresh()；待刷新状态拒绝检索，可重试。hybridSearch 使用 DBMS_HYBRID_SEARCH.GET_SQL，由数据库执行全文+向量 RRF（常数 60，窗口>=20），无客户端融合。单进程队列防止 SDK 会话变量交叉；知识库切换丢弃旧结果。

同机实测（2026-10-29）。 Windows 11、i7-14700KF、28 逻辑线程、32 GB 可见内存；机器显卡 GTX 1050 Ti，浏览器报告 NVIDIA/Pascal WebGPU adapter，不支持 shader-f16；Chromium 156，WASM 4 线程，seekdb Docker 4 CPU/2 GB。固定 24 篇合成中英文文档/12 条分级查询，预热后混合检索 3 轮，所有样本保留；端到端包含 query embedding、HTTP/DB 和结果绘制。

- FP32/WASM、batch1/逐批刷新：向量化 5.00 片段/s；DB 混合检索中位数 89.94 ms；端到端 166.50 ms（p95 185.72 ms）；混合 Recall@5 0.9583、nDCG@5 0.9875。
- INT8/WASM、batch4/统一刷新：6.76 片段/s；DB 89.98 ms；端到端 216.43 ms（p95 233.39 ms）；混合 Recall@5 1.0000、nDCG@5 0.9922。
- INT8/WebGPU、batch4/统一刷新：20.23 片段/s；DB 89.62 ms；端到端 149.92 ms（p95 166.69 ms）；混合 Recall@5 1.0000、nDCG@5 0.9922。

质量与解释。 所有精度/后端的独立语义检索 Recall@5 0.9583、nDCG@5 0.9856，均满足预先固定的绝对下降<=0.02 门槛。固定 INT8/batch4/刷新策略时，WebGPU 向量化吞吐为 WASM 的 2.99×，端到端中位数减少 30.73%。INT8/WASM 查询比 FP32 慢，不能声称量化必然加速。batch+刷新是组合优化，不分别归因。模型加载含文件读取/会话创建/预热，FP32 首次浏览器缓存 9.72 s，INT8 缓存加载 1.01 – 1.25 s；缓存状态不同，不将差值计为量化收益，也不当作公网下载时间。合成小评测集、顺序执行及单机结果不代表标准榜单；原生 Edge、物理无 GPU 设备和 embedded 模式未实测。

复核入口。 artifacts/submission-benchmark.json 保留逐查询 ID/原始阶段时间/模型 SHA-256，npm run benchmark -- artifacts/submission-benchmark.json 独立复算指标和中位数；artifacts/results.md 为完整摘要。数据库 7 项真实验收、4 项单元测试、自动降级与算子等价证据均附于 artifacts/。浏览器复测入口 /?benchmark=1；完整启动、恢复及边界见 README.md。